COURS VII

17 mars 2026

PLAN

- Modèles à variable expliquée binaire :
  - Logit
  - Probit
  - Linear Probability Model
- Exercice

VARIABLE EXPLIQUÉE BINAIRE

- **Variable expliquée binaire** : celle-ci ne prend que deux modalités codées par 0 et 1
- **Exemples** :
  - être allé voter ou non (1 = oui, 0 = non)
  - être admis en M2 ou non
  - avoir son permis ou non
  - avoir fait défaut de paiement ou non

MODÈLES À VARIABLE EXPLIQUÉE BINAIRE

- **On ne peut plus estimer <u>directement</u> un modèle linéaire standard**, car la variable dépendante ne prend que **deux valeurs** :

$$Y_i = 1 \text{ ou } Y_i = 0,$$

$$\text{donc } \beta X_i + \varepsilon_i = 0 \text{ ou } \beta X_i + \varepsilon_i = 1$$

- Il faut modéliser la **probabilité que l'événement se produise** :

$$P(Y_i = 1 \mid X_i)$$

MODÈLES À VARIABLE EXPLIQUÉE BINAIRE

Modèle linéaire généralisé (GLM)

- On introduit une **variable latente continue** Y_i^* qui dépend linéairement des variables explicatives :

$$Y_i^* = \beta X_i + \varepsilon_i \qquad \text{(modèle linéaire standard)}$$

- Y_i^* n'est pas observée directement.
- La variable observée Y_i est obtenue à partir de Y_i^* via une **fonction de lien** F:

$$\begin{cases} \text{Si } Y_i^* \geq 0 \text{ alors } Y_i = 1 \\ \text{Si } Y_i^* \leq 0 \text{ alors } Y_i = 0 \end{cases}$$

- La fonction de lien F transforme la relation linéaire de Y_i^* en une **probabilité comprise entre 0 et 1**.

MODÈLES À VARIABLE EXPLIQUÉE QUALITATIVE

Estimation de la probabilité pour une variable binaire

- On cherche à estimer la probabilité que $Y_i = 1$ sachant X_i :

$$P(Y_i = 1|X_i) = P(Y_i^* \geq 0|X_i) = P(\beta X_i + \varepsilon_i \geq 0|X_i) = P(\beta X_i \geq -\varepsilon_i)$$

- La probabilité s'exprime via la **fonction de répartition** de $-\varepsilon_i$
- La fonction de répartition F peut être choisie selon le modèle : logistique pour le logit, normale pour le probit.
- **Logit** : $\mathrm{P}(Y_i = 1) = \frac{1}{1+e^{-Y_i^*}}$
- **Probit** : $\mathrm{P}(Y_i = 1) = \Phi(Y_i^*)$, où Φ est la fonction de répartition de la loi normale.

LOGIT ET PROBIT

Propriétés et choix des modèles logit et probit

- **Probabilités contraintes** : Les deux modèles garantissent que $\mathrm{P}(Y_i = 1)$ reste **toujours comprise entre 0 et 1**.
- Transformation de la variable latente :
  - **Logit** → transforme Y_i^* en **log-odds,** $\log(\frac{p}{1-p})$
  - **Probit** → transforme Y_i^* en **probabilité via la fonction normale**
- Choix de la spécification :
  - Il n'y a pas de règle stricte.
  - Dépend souvent du domaine : par exemple, on utilise plutôt **les odds (logit)** en épidémiologie, alors que le **probit** est fréquent en économie et sciences sociales.
  - La différence entre logit et probit est très faible si les probabilités sont modérées.

ESTIMATION DE MODÈLES À VARIABLE EXPLIQUÉE BINAIRE

- Méthode d'estimation :
  - Les coefficients sont estimés par **maximum de vraisemblance** (ML).
  - L'estimation cherche les valeurs de β qui **maximisent la probabilité d'observer les données**.
- **Problème d'identification** : attention lorsque l'on interprète les coefficients estimés
  - Il faut **interpréter uniquement le signe des coefficients** (signe et significativité identiques dans les deux modèles)
- **Interprétation des effets marginaux en termes de probabilité** :
  - si $\beta > 0$, une hausse d'une unité de la variable explicative augmente la probabilité de l'évènement considéré (et inversement)

ESTIMATION DE MODÈLES À VARIABLE EXPLIQUÉE BINAIRE

- **Différence logit / probit**
  - **Logit** : coefficients en **log-odds**
  - **Probit** : coefficients sur l'échelle de la **fonction normale**
  - Les coefficients β **ne sont pas directement comparables** entre logit et probit, car ils dépendent de l'échelle de la fonction de lien.
  - Approximation courante :

$$\beta_{probit} \approx 0{,}55\, \beta_{logit}$$

ODDS ET LOG-ODDS

- **Odds d'un événement** :

$$\text{Odds} = \frac{nombre\ d'individus\ avec\ l'événement}{nombre\ d'individus\ sans\ l'événement}$$

  - Exprime le **rapport de chances** qu'un événement se produise.
- **Log-odds** (coefficients estimés par le logit sont sur l'échelle log-odds) :

$$\text{log odds} = \log(odds)$$

  - Transformation logarithmique des odds pour obtenir une **échelle continue et non bornée** $(-\infty, +\infty)$.
- **Relation avec la probabilité** p:

$$\text{odds} = \frac{p}{1-p}, \textit{log odds} = \log(\frac{p}{1-p})$$

  - Les **odds** vont de 0 à ∞
  - Les **log-odds** vont de $-\infty$ à $+\infty$

EFFETS MARGINAUX

- Pour un modèle logit :

$$p = \frac{1}{1 + e^{-X\beta}} \Rightarrow \frac{\partial p}{\partial X_j} = \beta_j \cdot p \cdot (1 - p)$$

  - p : probabilité prédite
  - β_j : coefficient du logit sur la variable X_j
- **Donc, pour passer des log-odds à un effet sur la probabilité**, on multiplie le coefficient par $p(1 - p)$.
- Pour le **probit**, c'est similaire mais avec la densité normale :

$$\frac{\partial p}{\partial X_j} = \beta_j \cdot \phi(X\beta)$$

  - ϕ : densité de la loi normale
  - β_j :coefficient sur l'échelle de la latente

SUR R

- Sur R, on estimera un GLM avec la fonction **glm()**
  - **Il faudra préciser :** family = binomial(link="logit") ou family = binomial(link=« probit")
- Pour obtenir les effets marginaux, on utilisera la fonction **logitmfx()** (package **mfx**)

LINEAR PROBABILITY MODEL (LPM)

- Modèle linéaire appliqué à une variable binaire
  - Estimation directe avec lm() en R
- **Avantages**
  - Les e**ffets marginaux sont directement estimés** (β_j = variation de probabilité associée à une unité de X_j)
  - Pas besoin de transformation logit/probit.
- **Limites**
  - La probabilité prédite peut **sortir de l'intervalle [0,1] :** c'est pas super pour les prédictions !
  - Donc moins adapté aux probabilités extrêmes (très proches de 0 ou 1).
  - Hypothèses classiques de linéarité et d'homoscédasticité **non respectées** (variance non constante).

EXERCICE 10 – MODÈLES À VARIABLE EXPLIQUÉE BINAIRE

PROBIT ET LOGIT (SIMPLES)