
COURS II

3 février 2026



PLAN

- Régression linéaire simple
- Régression linéaire multiple
- Exercices sous R

RÉGRESSION LINÉAIRE SIMPLE

- **Modélisation** : quel est l'effet moyen d'une variation d'une variable X sur une variable Y ?

$$Y = \alpha + \beta X + \varepsilon$$

- **Y**: **Variable dépendante**/expliquée/prédite/réponse
- **X**: **Variable indépendante**/explicative/préditive/contrôle
- **α** : **Constante**/ordonnée à l'origine
- **β** : **Coefficient** de la pente dans la relation entre Y et X
- **ε** : **Terme d'erreur**, perturbations qui affectent Y et viennent d'autres facteurs que X (inobservables)

ESTIMATEUR DES MOINDRES CARRÉS ORDINAIRES


- **Paramètres inconnus** : α et β
- **Estimateur des Moindres Carrés Ordinaires (MCO)** : sous conditions, le meilleur estimateur statistique de α et β qui minimise la somme des carrés des résidus

$$\hat{Y}_i = \hat{\alpha} + \hat{\beta}X_i$$

pour un échantillon de taille n issu de la population ($i = 1, \dots, n$)

avec le **résidu** $\hat{\varepsilon}_i = Y_i - \hat{Y}_i$

ESTIMATEUR DES MOINDRES CARRÉS ORDINAIRES



ESTIMATION ET INTERPRÉTATION

- **Estimation** : à partir d'un échantillon donné, calcul des valeurs de $\hat{\alpha}$ et $\hat{\beta}$ (estimateurs des MCO)
- **Interprétation** :
 - **Significativité globale et pouvoir explicatif** de la régression (R^2)
 - **Significativité statistique** de ces coefficients (test d'hypothèse, statistiquement différents de 0 ou non ?)
 - **Valeur moyenne des estimateurs** $\hat{\alpha}$ et $\hat{\beta}$

SIGNIFICATIVITÉ GLOBALE ET POUVOIR EXPLICATIF


- **Qualité d'ajustement** de la droite de régression MCO aux données
- **Coefficient de détermination (R^2)** : entre 0 et 1 (1 = ajustement parfait)
- **Interprétation** : $R^2 \times 100$ est le pourcentage de la variation de Y qui est expliquée par X

TEST DE SIGNIFICATIVITÉ DES COEFFICIENTS

- **Test de Student (t-test)** : exemple de test de significativité des coefficients estimés d'une régression
- **Hypothèses** $\begin{cases} H_0: \hat{\beta} = 0 \\ H_1: \hat{\beta} \neq 0 \end{cases}$ ← **Hypothèse nulle** : absence d'effet de X sur Y
- **Statistique de Student** : $T = \frac{\hat{\beta}}{\sigma_{\hat{\beta}}}$ avec $\sigma_{\hat{\beta}}$ l'écart-type de $\hat{\beta}$ (standard errors)
- **Conclusion du test** : on rejette H_0 au seuil de significativité de 5 % si $|T|$ est > 1.96 ou valeur-p $< 0,05$.
- **Interprétation** : statistiquement (non-)significative au seuil de 5%.

TEST DE SIGNIFICATIVITÉ DES COEFFICIENTS

α est le seuil de rejet de H_0




VALEUR MOYENNE DES ESTIMATEURS

- $\hat{\alpha}$: valeur estimée de Y lorsque $X = 0$
- $\hat{\beta}$: variation de \hat{Y}_i suite à une variation d'une unité de X
- **Attention** : interprétation du coefficient de régression pour un modèle linéaire (niveau-niveau)

INTRODUIRE DE LA NON-LINÉARITÉ

- **Linéaire** : l'effet d'une variation de X sur Y est identique pour toute valeur initiale de X
- **Exemple** : chaque année d'éducation supplémentaire augmente le salaire estimé du même montant
- **Problème** : rendement d'échelle croissant de l'éducation (chaque année d'étude supplémentaire a un effet croissant sur les salaires)
- **Modèle** : log (logarithme naturel) – niveau
- **Autre modèle non-linéaire** : log – log (pour les élasticités)

INTRODUIRE DE LA NON-LINÉARITÉ



© Cengage Learning, 2013

INTRODUIRE DE LA NON-LINÉARITÉ

Tableau 2.3 Synthèse des formes fonctionnelles ayant recours au log naturel			
Modèle	Variable dépendante	Variable indépendante	Interprétation de β_1
Niveau-niveau	y	x	$\Delta y = \beta_1 \Delta x$
Niveau-log	y	$\log(x)$	$\Delta y = (\beta_1 / 100) \% \Delta x$
Log-niveau	$\log(y)$	x	$\% \Delta y = (100 \beta_1) \Delta x$
Log-log	$\log(y)$	$\log(x)$	$\% \Delta y = \beta_1 \% \Delta x$

© Cengage Learning, 2013

Scanné avec CamScanner

- **Niveau – niveau** : variation de β unité de \hat{Y}_i suite à une variation d'une unité de X
- **Niveau – log** : variation de $\beta/100$ unités de \hat{Y}_i suite à une variation d'1% de X
- **Log – niveau** : variation de $100 \times \beta$ % de \hat{Y}_i suite à une variation d'une unité de X
- **Log – log** : variation de $\beta\%$ de \hat{Y}_i suite à une variation d'1% de X

RÉGRESSION LINÉAIRE DANS R

- Régression linéaire dans R : **lm(variable à expliquer ~ variable(s) explicative(s),...)**
- Exemples :

```
model <- lm(nomvar1 ~ nomvar2, data = mesdata)
```

```
model <- lm(mesdata$nomvar1 ~ mesdata$nomvar2)
```

- Données manquantes : **na.omit** ou **na.fail**

- Exemples :

```
model <- lm(nomvar1 ~ nomvar2, na.action = na.omit)      par défaut
```

```
model <- lm(nomvar1 ~ nomvar2, na.action = na.fail)      produit un avertissement si NA(s)
```

- Opérateur Retard : **lag(variable, nombre de retard)**

RÉGRESSION LINÉAIRE DANS R

- Visualiser les estimations : **summary()**

- Exemple :

```
monmodel <- lm(nomvar1 ~ nomvar2, data = mesdata)
```

```
summary(monmodel)
```

ensemble des *informations de la régression (dont tests, significativité, etc.)*

```
monmodel$coef ou coef(monmodel)
```

pour les coefficients estimés

```
monmodel$residuals ou residuals(monmodel)
```

pour les résidus

EXERCICE 2 - RÉGRESSION LINAIRe SIMPLE

QUEL EST L'IMPACT DE LA VITESSE SUR LA DISTANCE DE FREINAGE D'UNE VOITURE ?



RÉGRESSION LINÉAIRE MULTIPLE

- **Estimation :**

$$\hat{Y} = \hat{\alpha} + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2 + \hat{\varepsilon}_i$$

- $\hat{\alpha}$ est la valeur estimée de Y quand $X_1 = 0$ et $X_2 = 0$
 - $\hat{\beta}_1$ et $\hat{\beta}_2$ sont les **effets marginaux** (*ceteris paribus*) :
 - Variation estimée de Y suite aux variations de X_1 quand X_2 est maintenu constant
 - Variation estimée de Y suite aux variations de X_2 quand X_1 est fixé
- **Biais** : inclusion de variables non-pertinentes (**sur-spécification** du modèle), variable omise (**sous-spécification**)

EXERCICE 3 - RÉGRESSION LINÉAIRE MULTIPLE

TEMPS RECORD SUR DIFFÉRENTES COURSES À PIED EN ECOSSE

