COURS VI

11 mars 2026

PLAN

- Estimation de modèles avec données de panels :
  - Problème d'endogénéité
  - Effets fixes et aléatoires
  - Estimateurs « within » et « between »
- Exercice

DONNÉES DE PANEL

- **Données longitudinales (de panel) :** plusieurs individus statistiques et plusieurs périodes
- Variables (Y_{it}) indexées par i pour les **individus** (de 1 à N) et par t pour les **périodes** (de 1 à T)
- $\boldsymbol{N \times T}$ **observations** avec :
  - $N > T$ (données micro)
  - $N < T$ (données macro)
- **Exemples :** situation financière de 1500 entreprises sur 10 ans, consommation de 20000 ménages sur 4 ans, etc.

TRAVAILLER SUR DONNÉES DE PANEL DANS R

- **Package :** **plm** ou **fixest**
- **Enjeux :** R doit pouvoir reconnaître les données temporelles qui correspondent à un même individu
- **Présentation :** data.frame avec un indice individuel (dans la première colonne) et un indice temporel (dans la deuxième colonne)

HYPOTHÈSES DU MODÈLE DE RÉGRESSION LINÉAIRE

1. Modèle linéaire
2. X non stochastique
3. Valeur moyenne du terme d'erreur nulle
4. Homoscédasticité (constance de la variance du terme d'erreur)
5. Absence d'autocorrélation des erreurs (covariance du terme d'erreur nulle)
6. **Covariance nulle entre ε et X**
7. Nombre d'observations supérieur au nombre de paramètres
8. X bornés dans leur ensemble
9. Modèle correctement spécifié
10. Absence de colinéarité parfaite (régression multiple)

PROBLÈME D'ENDOGÉNÉITÉ

- Problème fréquent : **caractéristiques individuelles inobservables non-contrôlées** par le statisticien
- **Biais de variable omise** si les facteurs individuels inobservables omis (dans le terme d'erreur ε_{it}) sont corrélés avec les variables explicatives X_{it}
- **Exemple :**
  - Expliquer le salaire des individus par leur niveau de diplôme et leur secteur
  - Mais le salaire dépend aussi de variables spécifiques à l'individus qui ne sont pas directement mesurables : motivation personnelle, capacités de négociation, expérience, productivité, etc.

ESTIMATION DE MODÈLES AVEC DONNÉES DE PANELS

- **Résoudre le problème d'endogénéité** en estimant des modèles avec données de panels
- **Contrôler les facteurs inobservés ou non-mesurés** qui varient entre individus mais pas dans le temps

MODÈLE DE RÉGRESSION LINÉAIRE SIMPLE AVEC EFFETS FIXES INDIVIDUELS

$$\boldsymbol{Y_{it} = \beta_0 + \beta_1 X_{it} + \beta_2 Z_i + \varepsilon_{it}}$$

- **Comment estimer $\boldsymbol{\beta_1}$ sans biais si $\boldsymbol{Z_i}$ est inobservé ?**
  - Remplacer $\beta_0 + \beta_2 Z_i$ par une constante individuelle α_i (une pour chaque individu)
- **Effet fixe :**
  - **individuel** (α_i) : varie entre individus (mais pas dans le temps)
  - **temporel** (ν_t) : varie dans le temps mais pas entre individus
- Inclure des **effets fixes** (au niveau i, α_i), est **équivalent au fait d'inclure des variables binaires** (« dummies ») (pour chaque observation i, égales à 1 pour l'individu i, 0 sinon)

ESTIMATEUR « WITHIN » (INTRA)

- **Estimateur « within »** obtenu par l'estimation MCO suivante :

$$\boldsymbol{Y_{it} = \beta_1 X_{it}} + \alpha_i + \boldsymbol{\varepsilon_{it}}$$

- **Equivalent à l'estimateur obtenu par :**

$$\boldsymbol{\widetilde{Y}_{it} = \beta_1 \widetilde{X}_{it}} + \boldsymbol{\tilde{\varepsilon}_{it}}$$

avec $\tilde{Y}_{it} = Y_{it} - \overline{Y}_i$ et $\tilde{X}_{it} = X_{it} - \bar{X}_i$, les d**éviations individuelles autour des moyennes dans le temps, spécifiques à chaque individu *i***, $\overline{Y}_i = \frac{1}{T}\sum_{t=1}^{T} Y_{it}$ et $\bar{X}_i = \frac{1}{T}\sum_{t=1}^{T} X_{it}$

- Les α_i disparaissent car $\widetilde{\alpha}_i = \alpha_i - \overline{\alpha}_i = 0$

ESTIMATEUR « WITHIN » (INTRA)

- Dans un modèle avec effets individuels, l'estimateur de $\boldsymbol{\beta_1}$ correspond au changement de Y (en unités) associé à la déviation d'une unité de X par rapport à sa moyenne.
- Formellement, il s'écrit :

$$\hat{\beta}_{FE} = \frac{\sum_{i=1}^{N}\sum_{t=1}^{T}(X_{it} - \bar{X}_i)(Y_{it} - \bar{Y}_i)}{\sum_{i=1}^{N}\sum_{t=1}^{T}(X_{it} - \bar{X}_i)^2}$$

- Avec $\bar{X}_i = \frac{1}{T}\sum_t X_{it}$, la moyenne individuelle (même chose pour Y).

ESTIMATEUR « WITHIN » (INTRA)

- **Estimateurs MCO sans biais**
- Mais les **termes d'erreurs ne plus indépendants** (corrélés au niveau intra-individuel) :

$$cov(v_{it}, v_{it+1}) \neq 0$$

- Il faut **modifier le calcul des erreurs-types** : fully robust standard errors, clustered standard errors

ESTIMATEUR « WITHIN » (INTRA)

- Pour capter l'effet de X sur Y dans un modèle avec effets fixes individuels, il faut nécessairement **des variations temporelles dans X pour chaque individu**, sinon l'effet ne peut pas être estimé.
- On ne peut pas estimer le modèle suivant :

$$\boldsymbol{Y_{it} = \beta_1 X_i} + \alpha_i + \boldsymbol{\varepsilon_{it}}$$

- Ici, X ne varie pas dans le temps, alors il sera absorbé par les effets fixes individuels α_i.

ESTIMATEUR « TWO-WAY FIXED EFFECTS » (TWFE)

- Le **TWFE** permet de contrôler à la fois :
  - des **caractéristiques permanentes propres à chaque individu** (α_i)
  - des **chocs communs à tous les individus à chaque période** (λ_t)

$$Y_{it} = \beta X_{it} + \alpha_i + \lambda_t + \varepsilon_{it}$$

- $\widehat{\beta}$ mesure l'effet moyen de X sur Y, après avoir retiré :
  - les différences permanentes entre individus
  - les chocs communs à toutes les unités à un moment donné
- La force de l'estimateur « TWFE » est qu'il permet de réduire encore davantage les biais dû aux variables omises (si des chocs communs à tous les individus existent).

ESTIMATEUR « TWO-WAY FIXED EFFECTS » (TWFE)

- L'estimateur s'écrit :

$$\hat{\beta}_{TWFE} = \frac{\sum_{i=1}^{N}\sum_{t=1}^{T}(X_{it} - \bar{X}_i - \bar{X}_t + \bar{X})(Y_{it} - \bar{Y}_i - \bar{Y}_t + \bar{Y})}{\sum_{i=1}^{N}\sum_{t=1}^{T}(X_{it} - \bar{X}_i - \bar{X}_t + \bar{X})^2}$$

- Avec :
  - $\bar{X}_i = \frac{1}{T}\sum_t X_{it}$: moyenne individuelle
  - $\overline{X_t} = \frac{1}{N}\sum_i X_{it}$: moyenne temporelle
  - $\bar{X} = \frac{1}{NT}\sum_i \sum_t X_{it}$: moyenne globale
- Cette formule **centre X et Y à la fois sur l'individu et sur la période.**

ESTIMATION « WITHIN » DANS R

- **Fonction panel linear model plm(), ou fixed effects ordinary least squares feols()**
  - Réalisent directement la transformation des variables de l'estimation within

ESTIMATEUR DES MOINDRES CARRÉS GÉNÉRALISÉS (MCQG)

- **Modèle à effets aléatoires :**
  - Effets individuels : **variables aléatoires** (plus des paramètres)
  - Plus efficace quand les **effets individuels sont exogènes par rapport aux variables explicatives**
- **Test d'Hausman :**
  - Fonction **phtest()**
  - **H0 :** covariance nulle entre effets individuels et variables explicatives (effets individuels exogènes)
  - Si **H0 rejetée** (t-stat grande), on <u>retient le modèle avec effets fixes</u> (rejet du modèle effets aléatoires)

ESTIMATION « POOLED » ET « BETWEEN »

Autres approches sur données de panel (moins pertinentes et moins robustes) :

- **Pooled OLS**
  - Consiste à empiler toutes les observations du panel, comme si c'était une simple coupe transversale.
  - Ne tient pas compte de l'hétérogénéité individuelle (pas d'effets fixes)
  - Utilise toutes les observations comme si elles étaient indépendantes
  - Le coefficient mesure une corrélation globale, mélangeant différences entre unités et évolution au sein des unités
- **Between estimator**
  - Consiste à moyenner chaque variable dans le temps pour chaque unité, puis on fait une régression en coupe.
  - Ne considère que la variation entre unités, ignore la variation dans le temps au sein des unités.

Ces estimations sont descriptives et moins fiables pour l'identification causale que le modèle à effets fixes (« within »).

ESTIMATEUR « BETWEEN » (INTER)

- **Modèle avec effets fixes :**

$$Y_{it} = \beta_1 X_{it} + \alpha_i + \varepsilon_{it}$$

- **Estimateur « between »** obtenu par l'estimation MCO suivante :

$$\boldsymbol{\bar{Y}_{it} = \beta_1 \bar{X}_i + \alpha + (\alpha_i - \alpha + \bar{\varepsilon}_i)}$$

- Inclusion de effets fixes dans le terme d'erreur $(\alpha_i - \alpha + \bar{\varepsilon}_i)$ est l'erreur composite, où α est la constante globale pour OLS, définie par $\alpha = \frac{1}{N}\sum_i \alpha_i$
- Donc, l'estimateur « between » n'est consistant que si l'on a des **effets individuels aléatoires**

EXERCICE 9 - MODÈLES AVEC DONNÉES DE PANEL

EFFET DE LA VALEUR ET DU STOCK DE CAPITAL SUR L'INVESTISSEMENT BRUT POUR 10 FIRMES ENTRE 1935 ET 1954